

Laporan Praktikum Kontrol Cerdas

Nama : Gunawan Wibisono
NIM : 224308083
Kelas : TKA – 7D
Akun *Github* (Tautan) : <https://github.com/gunawanwibisono83>
Student Lab Assistant : -

1. Judul Percobaan

Deep Learning for Intelligent Control Systems

2. Tujuan Percobaan

Tujuan dilakukannya percobaan ini yaitu :

- a. Mahasiswa dapat memahami konsep dasar *deep learning*.
- b. Mahasiswa dapat mengimplementasikan model *deep learning Convolutional Neural Network* untuk klasifikasi objek.
- c. Mahasiswa dapat menggunakan *library TensorFlow* dalam membangun model *deep learning*
- d. Mahasiswa dapat mengintegrasikan model *Convolutional Neural Network* dengan *Computer Vision* dalam mendeteksi objek secara *real-time*.
- e. Mahasiswa dapat mengembangkan mode *Night Vision* untuk deteksi objek dalam kondisi pencahayaan rendah.

3. Landasan Teori

Deep learning adalah salah satu bidang *machine learning* yang memanfaatkan banyak *layer* pengolahan informasi nonlinier untuk melakukan ekstraksi fitur, pengenalan pola, dan klasifikasi. Menurut Goodfellow, dkk. (2016), *deep learning* adalah sebuah pendekatan dalam penyelesaian masalah pada sistem pembelajaran komputer yang menggunakan konsep hierarki. Konsep hierarki membuat komputer mampu mempelajari konsep yang kompleks dengan menggabungkan dari konsep-konsep yang lebih sederhana (Rosita Dewi,

2018). Pada dasarnya *deep learning* adalah implementasi konsep dasar dari *machine learning* yang menerapkan algoritma ANN dengan lapisan yang lebih banyak. Banyaknya lapisan tersembunyi yang digunakan antara lapisan masukan dan lapisan keluaran, maka jaringan ini dapat dikatakan *deep neural net* (Alam dkk., 2019).


Convolutional Neural Network (CNN) merupakan sebuah MLP (*Multilayer Perceptron*) yang didesain secara khusus untuk mengidentifikasi *image*/gambar dua dimensi. CNN meniru cara kerja otak manusia untuk mengenali objek yang dilihatnya. Dengan bantuan CNN, komputer dapat “melihat” dan “membedakan” berbagai objek. Fitur ini disebut dengan *image recognition*. CNN merupakan metode klasifikasi dari *deep learning* yang menggunakan *layer* konvolusi untuk mengonvolusi suatu *input* dengan filter. Secara garis besar CNN tidak berbeda dengan *neural network* biasa yang terdiri dari *neuron-neuron* yang memiliki *weight*, bias dan *activation function*. CNN terdiri dari 2 metode yaitu *training* (pembelajaran) menggunakan *backpropagation* serta klasifikasi menggunakan *forward backpropagation* (Husna, 2022).

TensorFlow merupakan sebuah pustaka perangkat lunak yang dikembangkan oleh tim *Google Brain* di bawah organisasi penelitian *Google Machine Intelligence*. Pustaka ini dirancang untuk mendukung pembelajaran mesin dan penelitian jaringan syaraf dalam (*deep learning*). TensorFlow menggabungkan aljabar komputasi dengan teknik optimasi kompilasi, sehingga mempermudah proses perhitungan berbagai ekspresi matematis yang kompleks, terutama yang membutuhkan waktu komputasi besar (Rosita Dewi, 2018).

Night vision adalah teknologi yang memungkinkan penglihatan dalam kondisi pencahayaan rendah dengan cara memperkuat cahaya yang ada (*image intensification*) atau mendeteksi panas dari objek (*thermal imaging*). Pada pemrosesan citra digital, efek *night vision* dapat disimulasikan melalui konversi gambar ke skala abu-abu dan pemberian *color mapping* sehingga tampilan lebih jelas meski cahaya minim. Teknologi ini banyak digunakan pada bidang militer, keamanan, transportasi, maupun penelitian, dan dalam praktikum ini diaplikasikan sebagai fitur tambahan pada sistem klasifikasi berbasis CNN untuk membantu visualisasi pada kondisi gelap

4. Analisis

Dalam praktikum ini, saya menerapkan salah satu cabang dari *deep learning*, yaitu *Convolutional Neural Network* (CNN) untuk melakukan klasifikasi objek menggunakan dataset *Intel Image Classification* yang diambil dari Kaggle. Dataset ini terdiri dari enam *class* yaitu bangunan, hutan, gletser, gunung, laut, dan jalan. Proses kerja sistem ini terbagi menjadi beberapa tahapan. Pertama, dataset diolah dengan *Image Data Generator* untuk melakukan normalisasi dan augmentasi data. Kedua data yang sudah diproses dimasukkan ke dalam arsitektur CNN yang terdiri dari lapisan konvolusi, *pooling*, *flattening*, dan *fully connected layer*, sehingga menghasilkan *output* berupa enam *class*. Ketiga, model dilatih menggunakan data *train* dan dievaluasi dengan data validasi hingga diperoleh parameter yang optimal. Pada percobaan pertama proses *training* dilakukan selama 5 *epoch* dan grafik tingkat akurasi & loss dapat dilihat pada Gambar 1.1. Selanjutnya, model yang telah dilatih disimpan dalam bentuk file *.h5*. Di akhir praktikum, model diintegrasikan dengan kamera menggunakan *OpenCV* untuk melakukan prediksi secara *real-time*.



Gambar 1.1 Grafik akurasi & loss 5 epochs

Sistem yang dijalankan secara *real-time* ini berhasil menampilkan hasil prediksi dalam bentuk label *class* dan tingkat (*confidence*) secara langsung di layar kamera dengan teks berwarna merah. Selain itu ditambahkan fitur *Night Vision* yang mengubah tampilan kamera menjadi skala abu-abu dengan efek *color mapping*, sehingga memudahkan pengguna dalam mengamati objek saat cahaya rendah. Meskipun fitur ini hanya berupa tambahan visual, pengguna tetap bisa melihat hasil prediksi baik saat menggunakan mode kamera normal maupun

mode *Night Vision*. Pada percobaan pertama dengan model yang dilatih selama 5 *epoch*, sistem hanya mampu mendeteksi objek dengan akurasi tinggi dan stabil pada gambar yang termasuk dalam *class* “*sea*” dan “*building*”. Sementara itu, untuk gambar dari *class* lainnya, tingkat akurasi yang dihasilkan relatif rendah. Kondisi ini dapat disebabkan oleh beberapa faktor, antara lain jumlah *epoch* yang masih terlalu sedikit sehingga model belum belajar secara optimal serta keterbatasan kualitas kamera yang digunakan dalam proses pengambilan citra. Penulis berasumsi bahwa tingginya akurasi pada *class* “*sea*” dan “*building*” dipengaruhi oleh dominasi warna yang lebih mencolok dan kontras dibandingkan dengan *class* lainnya sehingga model lebih mudah mengenali ciri-cirinya.

Secara keseluruhan, model CNN yang digunakan pada percobaan awal ini mampu melakukan proses klasifikasi gambar secara *real-time* dengan tingkat akurasi yang masih rendah, karena bergantung pada jumlah *epoch training* serta spesifikasi *hardware* yang digunakan. Akurasi model masih bisa ditingkatkan dengan menambah jumlah *epoch*, memperbanyak variasi dataset dari berbagai sumber, maupun menggunakan spesifikasi kamera yang lebih baik guna mendapatkan data yang lebih ilmiah.

5. Assignment

Pada praktikum ini dilakukan penyesuaian pada sistem klasifikasi gambar yang menggunakan *Convolutional Neural Network* (CNN). Pada percobaan sebelumnya, model hanya dilatih selama 5 (*epoch*) dan pengujian dilakukan dengan memakai foto dari ponsel. Namun dalam tugas ini, jumlah *epoch* ditingkatkan menjadi 15 agar hasilnya lebih akurat. Selain itu, pengujian tidak hanya dilakukan dengan gambar yang sudah siap/dari ponsel, tetapi juga langsung melalui kamera di lingkungan nyata, baik di luar ruangan seperti jalan raya maupun di dalam ruangan. Ternyata sistem yang dibuat mampu mengenali objek dalam enam *class* utama yaitu bangunan, hutan, kutub es, gunung, laut, dan jalan, serta menampilkan nama kategori beserta tingkat keakuratan secara langsung. Fitur *Night Vision* juga ditambahkan agar sistem bisa digunakan saat cahaya rendah.





Gambar 1.2 Grafik akurasi & loss 15 epochs

Berdasarkan Gambar 1.2 diatas, garis *validation* cenderung berbeda/tidak halus dibandingkan grafik keakuratan pada model 5 epoch. Perubahan ini menunjukkan bahwa dengan meningkatkan jumlah *epoch* dan berbagai kondisi pengujian dapat memengaruhi kemampuan serta keakuratan sistem klasifikasi objek berbasis CNN.

6. Data dan Output Hasil Pengamatan

No.	Variabel	Hasil Pengamatan	Keterangan
1.	Percobaan deteksi gambar laut dari <i>handphone</i> dengan model <i>training 5 epoch</i> .		Gambar laut yang di tampilkan di depan kamera <i>device</i> menggunakan <i>handphone</i> telah terdeteksi dalam <i>class</i> "Sea". Akurasi sistem mencapai 94,82% dalam kondisi pencahayaan ruangan normal.

2.	Percobaan deteksi gambar bangunan dari <i>handphone</i> dengan model <i>training</i> 15 <i>epoch</i> .		Gambar gedung yang di tampilkan di depan kamera <i>device</i> menggunakan <i>handphone</i> telah terdeteksi dalam <i>class</i> “ <i>Buildings</i> ”. Akurasi sistem mencapai 79,77% dalam kondisi pencahayaan ruangan normal.
3.	Percobaan deteksi gambar hutan dari <i>handphone</i> dengan model <i>training</i> 15 <i>epoch</i> .		Gambar hutan yang di tampilkan di depan kamera <i>device</i> menggunakan <i>handphone</i> telah terdeteksi dalam <i>class</i> “ <i>Forest</i> ”. Akurasi sistem masih 40,70% dalam kondisi pencahayaan ruangan normal.
4.	Percobaan deteksi kutub es dari <i>handphone</i> dengan model <i>training</i> 15 <i>epoch</i> .		Gambar kutub es yang di tampilkan di depan kamera <i>device</i> menggunakan <i>handphone</i> telah terdeteksi dalam <i>class</i> “ <i>Glacier</i> ”. Akurasi sistem mencapai 85,57% dalam kondisi pencahayaan ruangan normal.
5.	Percobaan deteksi gambar laut dari <i>handphone</i> dengan model <i>training</i> 15 <i>epoch</i> .		Gambar laut yang di tampilkan di depan kamera <i>device</i> menggunakan <i>handphone</i> telah terdeteksi dalam <i>class</i> “ <i>Sea</i> ”. Akurasi sistem masih 64,26% dalam kondisi pencahayaan ruangan normal.

6.	Percobaan deteksi gambar jalan dari <i>handphone</i> dengan model <i>training 15 epoch</i> .		Gambar jalan yang di tampilkan di depan kamera <i>device</i> menggunakan <i>handphone</i> telah terdeteksi dalam <i>class</i> “ <i>Street</i> ”. Akurasi sistem masih 33,32% dalam kondisi pencahayaan ruangan normal.
7.	Percobaan deteksi gunung dari <i>handphone</i> dengan model <i>training 15 epoch</i> .		Gambar gunung yang di tampilkan di depan kamera <i>device</i> menggunakan <i>handphone</i> telah terdeteksi dalam <i>class</i> “ <i>mountain</i> ”. Akurasi sistem masih 27,12% dalam kondisi pencahayaan ruangan normal.
8.	Percobaan deteksi dalam ruangan <i>real</i> dengan model <i>training 15 epoch</i> .		Hasil percobaan dalam ruangan terdeteksi dalam <i>class</i> “ <i>Buildings</i> ”. Akurasi sistem mencapai 90,21% dalam kondisi pencahayaan ruangan normal.

9.	Percobaan deteksi dalam ruangan <i>real</i> dengan model <i>training</i> 15 <i>epoch</i> .	Frame Class: buildings Accuracy: 77.81%  Night Vision Class: buildings Accuracy: 77.81% 	Hasil percobaan dalam ruangan terdeteksi dalam <i>class</i> “Buildings”. Akurasi sistem turun mencapai 77,81% dalam kondisi pencahayaan ruangan rendah.
10.	Percobaan deteksi jalan <i>real</i> dengan model <i>training</i> 15 <i>epoch</i> .	Frame Class: street Accuracy: 83.10%  Night Vision Class: street Accuracy: 83.10% 	Hasil percobaan jalan terdeteksi dalam <i>class</i> “Street”. Akurasi sistem mencapai 83,10% dalam kondisi pencahayaan normal.

11.	Percobaan deteksi jalan <i>real</i> dengan model <i>training</i> 15 <i>epoch</i> .		Hasil percobaan jalan terdeteksi dalam <i>class</i> “ <i>Street</i> ”. Akurasi sistem turun mencapai 78,17% dalam kondisi pencahayaan rendah.
-----	--	--	---

7. Kesimpulan

Berdasarkan percobaan yang telah dilakukan, maka dapat diambil kesimpulan sebagai berikut:

- Mahasiswa telah berhasil mengintegrasikan model *deep learning* (CNN) dengan *Night Vision* menggunakan dataset dari *Intel Image Classification* dalam klasifikasi objek secara *real-time*.
- Peningkatan jumlah *epoch* yang dilakukan dari 5 menjadi 15 menghasilkan akurasi yang lebih baik dalam mendeteksi objek secara *real-time*, sehingga jumlah *epoch* berpengaruh signifikan terhadap performa model.
- Tingkat pencahayaan sangat memengaruhi akurasi sistem dalam mendeteksi objek, dimana pada pencahayaan yang baik maka tingkat akurasi terbukti lebih tinggi dibandingkan pada pencahayaan rendah yang tingkat akurasinya menurun karena citra sulit dikenali.
- Performa sistem dalam klasifikasi objek secara *real-time* dipengaruhi oleh kualitas dataset, jumlah *epoch*, spesifikasi perangkat keras, serta kondisi pencahayaan saat pengujian.

8. Saran

Akurasi sistem dalam mendeteksi objek masih bisa ditingkatkan dengan menambah jumlah *epoch*, memperbanyak variasi dataset dari berbagai sumber, serta menggunakan spesifikasi kamera yang lebih baik dalam menangkap pencahayaan.

9. Daftar Pustaka

- Alam, I. F., Sarita, M. I., & Sajiah, A. M. (2019). IMPLEMENTASI DEEP LEARNING DENGAN METODE CONVOLUTIONAL NEURAL NETWORK UNTUK IDENTIFIKASI OBJEK SECARA REAL TIME BERBASIS ANDROID. *semanTIK*, 5(2), 237–244. <https://doi.org/10.5281/zenodo.3459374>
- Husna, I. N. (2022). Rancang Bangun Sistem Deteksi Dan Perhitungan Jumlah Orang Menggunakan Metode Convolutional Neural Network(CNN). *Seminar Nasional Fortei Regional 7. Forum Pendidikan Tinggi Teknik Elektro Indonesia Regional VII*. <https://journal.fortei7.org/index.php/sinarFe7/article/view/346/309>
- Rosita Dewi, S. (2018). *DEEP LEARNING OBJECT DETECTION PADA VIDEO MENGGUNAKAN TENSORFLOW DAN CONVOLUTIONAL NEURAL NETWORK* [Universitas Islam Indonesia]. https://dspace.uui.ac.id/bitstream/handle/123456789/7762/14611242_Syarifah%20Rosita%20Dewi_Statistika.pdf?sequence=1&isAllowed=y